

Relatório 4 - Prática Principais Bibliotecas e Ferramentas Python para Aprendizado de Máquina (I)

Igor Gabriel Wingert

1. Introdução

O objetivo do card foi praticar o uso de algumas ferramentas importantes para análise de dados e aprendizado de máquina, como Jupyter Notebook, NumPy e Pandas. Durante a prática, foram feitos exercícios simples para entender melhor como organizar códigos, trabalhar com arrays, criar tabelas, ler arquivos CSV e analisar dados de forma mais clara.

2. Desenvolvimento

2.1 Jupyter Notebook

Na prática, o Jupyter Notebook foi utilizado para organizar melhor os exercícios. Ele permite separar o conteúdo em células de texto e células de código, o que ajuda bastante no aprendizado. As células de texto, usando Markdown, foram usadas para escrever explicações sobre o que estava sendo feito. Já as células de código foram usadas para testar os comandos em Python e ver os resultados logo abaixo

Essa forma de trabalhar facilita bastante, porque não é necessário executar todo o código de uma vez. É possível testar uma parte, conferir o resultado e depois continuar. Isso também ajuda a encontrar erros com mais facilidade, pois cada trecho fica separado e mais simples de analisar.




Figura 1 – Organização básica de um notebook no Jupyter.

Fonte: Elaborado pelo autor.

Com isso, foi possível perceber que o Jupyter é uma ferramenta muito útil para estudar e praticar Python. Ele deixa o conteúdo mais organizado, misturando explicação e código no mesmo lugar. Isso é importante principalmente em atividades de análise de dado, onde é comum testar comandos, observar resultados e ir ajustando aos poucos

2.2 NumPy

O NumPy foi utilizado para trabalhar com dados numéricos de uma forma mais prática. Nos exercícios, foram usados arrays para guardar valores, como notas, horas de estudo ou outros números simples. O array funciona parecido com uma lista, mas é mais próprio para fazer cálculos com vários valores ao mesmo tempo.

A função `np.array()` foi usada para criar esses arrays com os dados. Depois disso, foram feitas algumas operações simples, como calcular média, maior valor e menor valor. A função `np.mean()` foi usada para calcular a média dos valores sem precisar fazer a soma manualmente. Já `np.max()` ajudou a encontrar o maior número do array, enquanto `np.min()` foi usada para encontrar o menor valor.

Também foi possível fazer filtros simples nos arrays, como selecionar apenas valores maiores que um certo número. Isso mostra que o NumPy ajuda bastante quando precisamos trabalhar com muitos dados numéricos, porque deixa os cálculos mais diretos e organizados.




Figura 2 – Funcionamento simples do NumPy na prática.

Fonte: Elaborado pelo autor

Com essa parte da prática, deu para entender que o NumPy é uma base importante para análise de dados e aprendizado de máquina. Antes de trabalhar com modelos mais avançados, muitas vezes é necessário fazer cálculos, comparar valores e organizar números, e o NumPy facilita bastante esse processo.

2.3 Pandas

O Pandas foi utilizado para trabalhar com dados em formato de tabela, parecido com uma planilha. Na prática, foi criado um DataFrame simples e também foi usado um arquivo CSV de clientes com 100 registros. Essa parte foi interessante porque mostrou uma situação mais próxima do uso real, onde os dados normalmente vêm de arquivos externos.

Com o comando `pd.read_csv()`, foi possível carregar o arquivo CSV para dentro do python. Depois disso, o `df.head()` foi usado para visualizar as primeiras linhas da tabela, o que ajuda a entender como os dados estão organizados. O `df.shape` mostrou a quantidade de linhas e colunas, enquanto o `df.info()` ajudou a ver informações gerais, como os tipos de dados de cada coluna.

Durante o exercício, também foram criadas novas colunas e feitos alguns filtros para analisar melhor as informações. Por exemplo, foi possível selecionar apenas alguns registros de acordo com uma condição. Também foi usado o `value_counts()` para contar quantas vezes cada categoria aparecia nos dados, o que ajuda bastante quando queremos entender melhor uma coluna.

Outro comando utilizado foi o `sort_values()`, que serviu para ordenar os dados com base em uma coluna. Isso é útil quando queremos ver os maiores ou menores valores primeiro. Além disso, também foram feitos testes simples com datas e textos, mostrando que o Pandas não serve apenas para números, mas também para trabalhar com diferentes tipos de informação.



Figura 3 – Leitura e análise de dados com Pandas.

Fonte: Elaborado pelo autor.

Essa parte foi a que mais se aproximou de uma situação real de análise de dados. Normalmente, antes de qualquer modelo de aprendizado de máquina, os dados precisam ser carregados, visualizados, filtrados e organizados. Com o Pandas, esse processo fica bem mais simples, pois ele permite trabalhar com tabelas de forma parecida com uma planilha, mas usando comandos em Python.

3. Conclusão

Com essa prática, foi possível entender melhor o papel de cada ferramenta estudada no card. O Jupyter Notebook ajudou na organização dos exercícios, deixando as explicações e os códigos no mesmo ambiente. O NumPy ajudou nos cálculos com dados numéricos, usando arrays e funções simples para média, maior e menor valor. Já o Pandas foi importante para ler e analisar dados em formato de tabela, principalmente usando arquivos CSV. No geral, essas ferramentas são importantes como base para projetos de ciência de dados e aprendizado de máquina, pois antes de criar modelos é necessário saber organizar, visualizar e entender os dados.

4. Referências

Udemy. Python for Data Science and Machine Learning Bootcamp. Jose Portilla / Pierian Training.s