

5 - Prática: Estatística p/ Aprendizado de Máquina (I)

Igor Gabriel Wingert

1. Introdução

O objetivo deste card foi revisar conceitos importantes de estatística e probabilidade, aplicando esses conteúdos em Python. Durante as aulas, foram vistos temas como tipos de dados, média, mediana, moda, variância, desvio padrão, percentis, distribuições de dados, visualização com Matplotlib e Seaborn, covariância, correlação, probabilidade condicional e Teorema de Bayes.

Além da parte teórica, também foram feitos códigos práticos no Jupyter Notebook. Esses códigos ajudaram a entender melhor como calcular medidas estatísticas, criar gráficos e analisar dados de forma simples. Com isso, foi possível perceber como a estatística é importante para interpretar dados antes de aplicar técnicas mais avançadas de aprendizado de máquina.

2. Desenvolvimento

No começo do card, foram revisados os tipos de dados, como dados numéricos, categóricos e ordinais. Esse conteúdo é importante porque cada tipo de dado precisa ser analisado de uma forma diferente. Por exemplo, dados numéricos podem ser usados em cálculos de média e desvio padrão, enquanto dados categóricos são mais usados para contagem e comparação entre grupos.

Depois disso, foram estudadas medidas estatísticas básicas, como média, mediana e moda. A média representa um valor geral dos dados, mas pode ser afetada por valores muito altos ou muito baixos. A mediana ajuda a entender o valor central dos dados, sendo mais resistente a valores extremos. Já a moda mostra o valor que mais aparece em um conjunto de dados.

Na prática, essas medidas foram calculadas usando Python. Foram criados dados simulados com NumPy, e depois foram aplicadas funções como `np.mean()`, `np.median()` e `stats.mode()`. Essa parte ajudou a entender que esses cálculos não servem apenas para obter números, mas para resumir melhor o comportamento dos dados.

Também foram estudadas a variância e o desvio padrão. A variância mostra o quanto os dados estão espalhados em relação à média. Já o desvio padrão mostra essa variação de uma forma mais fácil de interpretar, pois fica na mesma escala dos dados.

originais. Na prática, foram usadas as funções `var()` e `std()`, o que facilitou bastante a análise.

Outro assunto importante foram os percentis. Eles ajudam a entender a posição de um valor dentro de um conjunto de dados. Por exemplo, o percentil 90 indica que 90% dos valores estão abaixo daquele ponto. Isso é útil quando queremos analisar limites, faixas ou comparar valores dentro de uma distribuição.





Figura 1 – Visão geral dos principais conceitos estudados em estatística e probabilidade.

Fonte: Elaborado pelo autor.

As distribuições de dados também foram trabalhadas durante o card. Foram vistos exemplos de distribuição uniforme, normal, exponencial, binomial e de Poisson. A distribuição normal foi uma das mais importantes, pois aparece bastante em problemas reais e tem o formato conhecido de curva em sino. Já a binomial foi usada para representar situações com dois possíveis resultados, como sucesso ou fracasso. A distribuição de Poisson foi apresentada como uma forma de representar contagens em determinado intervalo.

Na parte de visualização, foram usadas as bibliotecas Matplotlib e Seaborn. Com o Matplotlib, foram criados gráficos simples, como histogramas, gráficos de linha, barras, dispersão, pizza e boxplot. Esses gráficos ajudam a visualizar melhor os dados, porque muitas vezes apenas olhar os números não deixa claro o comportamento do conjunto.



*Figura 2 – Exemplo de histograma para visualização da distribuição dos dados.
Fonte: Matplotlib Documentation – Histograms.*

Com o Seaborn, os gráficos ficaram mais completos visualmente. Foram usados gráficos como distplot, pairplot, scatterplot, jointplot, Implot, boxplot, swarmplot, countplot e heatmap. Essa parte foi interessante porque mostrou que a visualização dos dados ajuda a encontrar padrões, comparar categorias e perceber relações entre variáveis.

Na prática original, foi criado um dataset simples para aplicar parte do que foi aprendido. Com ele, foram calculadas medidas como média, mediana, moda, variância, desvio padrão e percentis. Também foram feitos gráficos simples, como histograma e gráfico de barras, para visualizar os dados. Essa prática ajudou a fixar melhor o conteúdo pois juntou os conceitos estatísticos com a programação em Python.

Também foi estudada a covariância e a correlação. A covariância mostra se duas variáveis variam juntas, mas seu valor pode ser difícil de interpretar sozinho. Já a correlação facilita essa interpretação, pois mostra a força e a direção da relação entre duas variáveis. Quando a correlação é próxima de 1, as variáveis tem relação positiva forte. Quando é próxima de -1, existe relação negativa forte. Quando é próxima de 0, a relação é fraca ou quase inexistente.

Por fim, foram estudadas probabilidade condicional e uma introdução ao Teorema de Bayes. A probabilidade condicional mostra a chance de um evento acontecer sabendo que outro evento já aconteceu. No exercício foi analisada a chance de compra de acordo com a faixa de idade. Depois, a solução mostrou um caso em que a probabilidade de compra era fixa, sem depender da idade.

Nesse caso, o resultado de $P(\text{Purchase} \mid 30\text{'s})$ ficou bem próximo de $P(\text{Purchase})$. Isso indica que a chance de compra era praticamente a mesma estando ou não na faixa dos 30 anos. Portanto, foi possível concluir que, naquele exemplo, idade e compra pareciam ser variáveis independentes.

3. Conclusão

Com esse card, foi possível entender melhor a importância da estatística e da probabilidade na análise de dados. As aulas mostraram que conceitos como média, mediana, desvio padrão, percentis, distribuições e correlação ajudam a interpretar melhor um conjunto de dados antes de qualquer etapa mais avançada.

A prática em Python foi importante porque permitiu aplicar esses conceitos diretamente no código. Usando NumPy, Matplotlib e Seaborn, foi possível gerar dados, calcular medidas estatísticas e criar gráficos para visualizar os resultados. Isso mostrou que a análise de dados não depende apenas de fórmulas, mas também da capacidade de interpretar os resultados.

4. Referências

Udemy. Statistics and Probability Refresher, and Python Practice.

Documentação Matplotlib. <https://matplotlib.org/stable/>