

8 - Prática: Web Scraping com Python p/ Ciência de Dados (II)

Igor Gabriel Wingert

1. Introdução

Nesse card, o objetivo foi acompanhar o vídeo Comprehensive Python BeautifulSoup Web Scraping Tutorial, que apresenta uma introdução prática ao web scraping com Python. Durante o vídeo, foram mostradas formas de acessar páginas web, interpretar o HTML e extrair informações úteis para uso posterior em análise de dados.

O conteúdo foi importante porque a coleta de dados é uma das primeiras etapas em projetos de Ciência de Dados. Antes de analisar ou visualizar informações, muitas vezes é necessário obter os dados de alguma fonte. Nesse caso, o vídeo mostrou como usar as bibliotecas requests e BeautifulSoup para acessar páginas, localizar elementos e transformar conteúdos da web em dados mais organizados.

2. Desenvolvimento

No início do vídeo, foi apresentado o uso da biblioteca requests para acessar uma página por meio de uma URL. Depois disso, o conteúdo retornado foi convertido em um objeto BeautifulSoup, permitindo visualizar e navegar pela estrutura HTML da página. Essa etapa ajudou a entender que o web scraping começa pelo acesso ao conteúdo da página e pela interpretação da sua estrutura

Ao longo da aula, foram utilizados métodos como find(), find_all() e select() para buscar elementos específicos do HTML. Com esses comandos, foi possível localizar títulos, parágrafos, links, listas e outros elementos da página. Também foram usados filtros por atributos, como id e class, além da extração de textos e links por meio de propriedades como string, get_text() e href.

Outro ponto importante foi o uso de expressões regulares com a biblioteca re. Essa parte mostrou como buscar textos que seguem determinado padrão, sem precisar conhecer exatamente o conteúdo completo. Isso pode ser útil quando a página possui muitos elementos semelhantes e é necessário pegar apenas os que contêm uma palavra ou padrão específico.

Na parte prática, também foi realizada a extração de uma tabela HTML. Os nomes das colunas e as linhas da tabela foram coletados com BeautifulSoup e depois organizados em um DataFrame com pandas. Essa etapa foi uma das mais

importantes para Ciência de Dados, pois mostrou como transformar uma tabela de uma página web em uma estrutura que pode ser analisada com Python.

Além disso, o vídeo apresentou um exemplo de download de imagem usando um arquivo separado chamado `download_image.py`. Nesse script, o código acessa a página, localiza uma imagem, monta a URL completa e salva o arquivo localmente. Isso mostrou que o web scraping não se limita apenas a extração de textos ou tabelas, mas também pode ser usado para baixar arquivos disponíveis em páginas web

No desafio final, o código acessou vários links encontrados na página e extraiu uma palavra secreta de cada um deles. Ao final, as palavras formaram uma frase (pedindo inscrição). Essa parte ajudou a reforçar a ideia de automação, pois o mesmo processo de acesso, leitura e extração foi repetido em várias páginas diferentes.




Figura 1 – Fluxo básico do processo de web scraping com Python
Fonte: Elaborado pelo autor

Para complementar o acompanhamento do vídeo, a prática aplica os conceitos aprendidos em um site que eu havia desenvolvido algum tempo atrás. O site foi criado para reunir informações e confirmação de presença do casamento de um amigo meu, ficando hospedado no GitHub Pages, embora não esteja sendo utilizado atualmente. Nessa prática, utilizei requests e BeautifulSoup para acessar a página, interpretar sua estrutura HTML e extrair algumas informações presentes no site. Com isso, foi possível aplicar de forma simples o que foi visto na aula, usando o web scraping em uma página real criada por mim.

3. Conclusão

Com o vídeo, foi possível entender melhor como funciona o processo de web scraping com Python. O vídeo mostrou que, a partir de uma página web, é possível acessar o HTML, localizar elementos importantes e extrair informações de forma automatizada.

A atividade também mostrou a importância de entender a estrutura da página antes de escrever o código. Cada informação pode estar dentro de uma tag, lista, tabela, link ou atributo diferente e por isso é necessário escolher corretamente os métodos de busca

O principal aprendizado foi que o web scraping pode ser uma ferramenta muito útil em Ciência de Dados, principalmente quando os dados necessários estão disponíveis em páginas da web. Com requests, BeautifulSoup e pandas, é possível coletar, organizar e preparar esses dados para análises posteriores.

4. Referências

https://www.youtube.com/watch?v=GjKQ6V_ViQE